

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

**Análise de sentimentos em avaliações de disciplinas:
um estudo de caso no ensino superior**

Erick Vansim Previato

Monografia - MBA em Ciência de Dados (CEMEAI)

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Erick Vansim Previato

Análise de sentimentos em avaliações de disciplinas: um estudo de caso no ensino superior

Monografia apresentada ao Centro de Ciências Matemáticas Aplicadas à Indústria do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Ciências de Dados.

Área de concentração: Ciências de Dados

Orientador: Prof. Dr. Wallace Correa de Oliveira Casaca

Versão original

São Carlos
2025

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados inseridos pelo(a) autor(a)

P944a Previato, Erick Vansim
 Análise de sentimentos em avaliações de
 disciplinas: um estudo de caso no ensino superior /
 Erick Vansim Previato; orientador Wallace Correa de
 Oliveira Casaca. -- São Carlos, 2025.
 38 p.

Trabalho de conclusão de curso (MBA em Ciência
de Dados) -- Instituto de Ciências Matemáticas e de
Computação, Universidade de São Paulo, 2025.

1. Análise de sentimentos. 2. Aprendizado de
máquina. 3. Processamento de linguagem natural. 4.
BERT. I. Casaca, Wallace Correa de Oliveira,
orient. II. Título.

Erick Vansim Previato

Sentiment analysis in subject evaluations: a case study in higher education

Monograph presented to the Centro de Ciências Matemáticas Aplicadas à Indústria do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, as part of the requirements for obtaining the title of Specialist in Data Science.

Concentration area: Data Science

Advisor: Prof. Dr. Wallace Correa de Oliveira Casaca

Original version

**São Carlos
2025**

*Este trabalho é dedicado a minha noiva, família e amigos
que sempre estiveram ao meu lado quando eu precisei.*

AGRADECIMENTOS

Agradeço à minha noiva, Maria Fernanda, por todo carinho, cuidado e incentivo para que eu siga sendo sempre uma pessoa melhor, e aos meus pais que sempre me apoiaram em todos os momentos da minha vida.

Quero agradecer também ao MBA em Ciências de Dados pela oportunidade e bolsa concedida, e ao ICMC pela disponibilização dos dados para a realização deste trabalho.

Por fim, agradeço ao meu orientador, Wallace, pela paciência, disponibilidade e cordialidade em compartilhar seu conhecimento para a realização deste trabalho.

*“Em tempos de crise, os sábios constroem pontes,
enquanto os tolos constroem muros.”*

T’Challa - Pantera Negra

RESUMO

PREVIATO, E. V. **Análise de sentimentos em avaliações de disciplinas: um estudo de caso no ensino superior.** 2025. ?? p. Monografia (MBA em Ciências de Dados) - Centro de Ciências Matemáticas Aplicadas à Indústria, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2025.

Resumo

Palavras-chave: Análise de sentimentos. Aprendizado de máquina. Processamento de linguagem natural. BERT.

ABSTRACT

PREVIATO, E. V. **Sentiment analysis in subject evaluations: a case study in higher education.** 2025. ?? p. Monograph (MBA in Data Sciences) - Centro de Ciências Matemáticas Aplicadas à Indústria, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2025.

This is the english abstract.

Keywords: Sentiment analysis. Natural language processing. machine learning. BERT.

LISTA DE FIGURAS

LISTA DE TABELAS

LISTA DE QUADROS

LISTA DE ABREVIATURAS E SIGLAS

BERT	Bidirectional Encoder Representations from Transformers
LDA	Latent Dirichlet Allocation
PCA	Principal Component Analysis
PLN	Processamento de Linguagem Natural
SVM	Support Vector Machines
USP	Universidade de São Paulo

SUMÁRIO

1 INTRODUÇÃO

1.1 Contextualização

A era digital em que vivemos tem gerado um volume de dados sem precedentes, transformando a forma como interagimos, consumimos e expressamos nossas opiniões. A internet, as redes sociais, fóruns, plataformas de ensino e reviews de produtos tornaram-se repositórios vastos de informações textuais, que refletem os pensamentos, sentimentos e percepções dos indivíduos sobre os mais diversos tópicos, produtos e serviços. No contexto educacional, a opinião do aluno, expressa através de comentários e realização de avaliações, torna-se uma opção para a melhoria contínua da qualidade do ensino e da gestão acadêmica das instituições educacionais (??).

A avaliação de disciplinas, em particular, é um processo crucial para instituições de ensino superior, pois permite coletar *feedback* direto dos estudantes sobre a qualidade do conteúdo, a metodologia de ensino, a atuação docente e a infraestrutura disponível (??). Em muitos dos casos, essas avaliações são analisadas manualmente: um processo que se torna inviável e ineficiente diante de um grande volume de dados gerado ao longo dos anos. A análise individualizada de milhares de comentários, como no caso da base de dados de mais de 8 mil avaliações de disciplinas de um instituto da Universidade de São Paulo (USP), consome tempo e recursos significativos, além de ser suscetível a vieses humanos e à perda de informações valiosas contidas no conjunto dos dados.

Posto o cenário acima, uma ferramenta proeminente é a Análise de Sentimentos (também conhecida como *Opinion Mining*): um campo da Inteligência Artificial e do Processamento de Linguagem Natural (PLN) que visa extrair, identificar e quantificar as polaridades emocionais (positiva, negativa ou neutra) expressas em textos (??). Por meio da aplicação de técnicas computacionais, a análise de sentimentos permite transformar dados textuais não estruturados em informações açãoáveis, oferecendo uma visão geral e automatizada do sentimento predominante em um conjunto de avaliações. Neste caso, o objetivo principal é compreender a atitude, o tom e as emoções expressas em um determinado conteúdo textual (??).

A aplicação da análise de sentimentos no contexto das avaliações de disciplinas de instituições de ensino permite que gestores educacionais obtenham uma compreensão do cenário de forma ágil e eficiente. Em vez de examinar cada comentário individualmente, é possível identificar padrões, tendências e pontos críticos em um conjunto de avaliações de uma ou mais disciplinas em um dado semestre, por exemplo. Isso facilita a tomada de decisões estratégicas, como a revisão de planos de ensino, a capacitação docente, a melhoria de recursos didáticos, a otimização das condições de oferta das disciplinas e a

evolução de equipamentos tecnológicos, contribuindo assim diretamente para a qualidade do ensino e a satisfação dos alunos.

1.2 Objetivos

A relevância da análise de sentimentos cresceu conforme a quantidade de informações também evoluiu, tornando-se uma ferramenta para gestão de tomada de decisão.

Portanto, este trabalho busca explorar a aplicação da análise de sentimentos para automatizar e otimizar o processo de avaliação de disciplinas, proporcionando aos gestores uma ferramenta poderosa para a compreensão da percepção dos alunos e a consequente melhoria contínua da qualidade educacional.

Em termos de aplicabilidade e prova de conceito, a pesquisa visa validar a escalabilidade da solução por meio de um estudo de caso real utilizando a base de dados de um instituto da USP, demonstrando seu potencial para replicação em outras instituições. Os fundamentos teóricos que embasam esses objetivos são detalhados no Capítulo ??.

2 REVISÃO BIBLIOGRÁFICA

2.1 Análise de Sentimentos

A Análise de Sentimentos, ou *Opinion Mining*, é um subcampo do Processamento de Linguagem Natural (PLN) que se dedica à identificação e extração da polaridade (positiva, negativa, neutra) e da subjetividade de textos, classificando-os de acordo com o sentimento expresso (??). O objetivo principal é determinar a atitude de um autor em relação a um tópico, produto, serviço ou entidade. Essa atitude pode ser um julgamento ou avaliação, um estado emocional, como raiva ou alegria, ou a intenção comunicativa, como a compra de um produto, por exemplo (??).

A origem da análise de sentimentos pode ser traçada até o início dos anos 2000, impulsionada pelo crescimento exponencial da internet e o consequente aumento na produção de conteúdo textual, como avaliações de produtos, posts em blogs e fóruns de discussão (??). Embora o estudo da opinião em textos não seja um conceito novo, a abordagem computacional para extrair e resumir essas opiniões ganhou destaque com o advento de técnicas de Aprendizado de Máquina e o volume massivo de dados disponíveis. Os trabalhos pioneiros de Pang, Lee e Vaithyanathan (2002) e Turney (2002) são frequentemente citados como marcos iniciais nesse campo, demonstrando a viabilidade de aplicar algoritmos de aprendizado supervisionado para classificar a polaridade de textos.

2.1.1 Tipos e Níveis de Análise de Sentimentos

A análise de sentimentos pode ser categorizada em diferentes tipos e níveis de granularidade, dependendo do objetivo e da profundidade da análise desejada. A Análise de Sentimentos Baseada em Léxico utiliza léxicos (listas de palavras) pré-definidos, onde cada léxico é associado a uma pontuação de sentimento (positiva, negativa ou neutra). O sentimento de um texto é então calculado com base na soma ou média das pontuações das palavras presentes no texto (??). Embora simples e eficaz para muitas aplicações, sua principal limitação reside na incapacidade de lidar com ironia, sarcasmo e o contexto em que as palavras são utilizadas.

A Análise de Sentimentos Baseada em Aprendizado de Máquina utiliza algoritmos de aprendizado de máquina, supervisionado ou não supervisionado, para classificar o sentimento de um texto. Modelos são treinados em grandes conjuntos de dados rotulados, no caso supervisionado, para aprender a associar características do texto a uma polaridade de sentimento (??).

Em relação aos níveis de granularidade, a análise de sentimentos pode ser realizada em três níveis: nível de documento, nível de sentença e nível de aspecto ou entidade.

No nível de documento, a classificação do sentimento é realizada em um documento inteiro como positivo, negativo ou neutro. É útil para obter uma visão geral do sentimento em relação a um tópico (??).

No nível de sentença, o sentimento de cada frase é analisado individualmente dentro de um documento. Permite identificar nuances e diferentes sentimentos expressos em diferentes partes de um texto (??).

Já no nível de aspecto, o mais granular, foca na identificação do sentimento em relação a aspectos ou entidades específicas dentro de um texto (??). Por exemplo, em uma avaliação de disciplina, pode-se analisar o sentimento em relação ao professor, material didático ou metodologia de avaliação. Este nível é particularmente relevante para o presente trabalho, pois permite identificar sentimentos específicos para as categorias e critérios das avaliações.

2.1.2 Aprendizado Supervisionado e Não Supervisionado na Análise de Sentimentos

A escolha entre abordagens de Aprendizado Supervisionado e Não Supervisionado é fundamental na construção de um modelo de análise de sentimentos robusto e efetivo. A frente de Aprendizado Supervisionado requer um conjunto de dados rotulados, onde cada exemplo de texto já possui uma polaridade de sentimento predefinida, seja ela positiva, negativa ou ainda neutra. O algoritmo aprende a mapear características do texto a partir desses rótulos (??). A vantagem é que geralmente resulta em modelos com maior precisão quando há dados rotulados de alta qualidade e em quantidade suficiente. Já a desvantagem é com relação à rotulagem de dados, pois é um processo demorado e custoso, especialmente para grandes volumes de texto (??). Algoritmos populares na vertente de Aprendizado Supervisionado são: Máquinas de Vetores de Suporte (SVM), *Naive Bayes*, Regressão Logística, Redes Neurais e Árvores de Decisão (??).

O Aprendizado Não Supervisionado não requer um conjunto de dados rotulados. Algoritmos desta família buscam padrões e estruturas inerentes aos dados para inferir o sentimento. Métodos baseados em léxico são exemplos de abordagens não supervisionadas, onde a polaridade é inferida a partir de dicionários de sentimentos (??). Outras técnicas, como modelagem de tópicos, podem ser usadas para identificar temas e associar sentimentos a eles. Uma vantagem é que não exige o esforço de rotulagem manual, tornando-o mais escalável para grandes volumes de dados. Já a desvantagem é que pode apresentar menor precisão em comparação com abordagens supervisionadas e tem dificuldade em capturar nuances de linguagem, como sarcasmo e negação (??). Algoritmos clássicos na frente de Aprendizado Não Supervisionado são: Análise de Componentes Principais (PCA), *K-Means* (para agrupamento de textos por sentimento implícito) e Modelagem de Tópicos como o *Latent Dirichlet Allocation* (LDA) (??).

Para o contexto das avaliações de disciplinas, onde a rotulagem manual de 8 mil

comentários seria um processo exaustivo, a consideração de abordagens não supervisionadas ou a combinação com técnicas semi-supervisionadas (onde uma pequena parte dos dados é rotulada manualmente e usada para treinar um modelo inicial) pode ser uma estratégia viável. Porém, caso haja possibilidade de utilizar a abordagem supervisionada, ou seja, caso não tenha um custo muito elevado para realizar a rotulagem dos dados, pode-se tornar uma estratégia mais assertiva.

2.1.3 Fatores Importantes na Análise de Sentimentos

A aplicação da análise de sentimentos não é trivial e envolve a consideração de diversos fatores que podem impactar a precisão e a utilidade dos resultados:

- Pré-processamento de Texto: Etapa utilizada para limpar e normalizar o texto antes da análise. Inclui a remoção de *stopwords* (palavras comuns como "e", "o", "a"), pontuações, caracteres especiais, lematização (redução de palavras à sua forma base) e *stemming* (redução de palavras ao seu radical) (??).
- Tratamento de *Negation*: A presença de negações ("não gostei", "nunca farei") pode inverter o sentido de uma frase e deve ser tratada adequadamente para evitar classificações errôneas (??).
- Linguagem Específica e Gírias: Termos específicos de um domínio (como jargões acadêmicos) e gírias podem não estar presentes em léxicos genéricos e requerem adaptação ou construção de léxicos especializados (??).
- Ironia e Sarcasmo: A detecção de ironia e sarcasmo é um desafio significativo na análise de sentimentos, pois a polaridade literal das palavras é oposta à intenção do autor (??).
- Emojis e Emoticons: Em textos informais, emojis e emoticons são expressivamente utilizados para transmitir sentimentos e devem ser considerados na análise (??).
- Modelo de Idioma: A análise de sentimentos para a língua portuguesa apresenta desafios específicos devido à sua complexidade gramatical, polissemia e riqueza de sinônimos, exigindo modelos e recursos linguísticos adaptados (??).

2.1.4 Ferramentas e Modelos

Nos últimos anos, a área de análise de sentimentos tem sido significativamente impactada pelo avanço dos modelos de Deep Learning e Transformers. Esses modelos, pré-treinados em grandes volumes de texto, demonstraram capacidades impressionantes de compreensão de linguagem e geração de texto, superando abordagens tradicionais em muitas tarefas de PLN, incluindo a análise de sentimentos (??).

É importante ressaltar que a escolha da ferramenta ou modelo depende de diversos fatores, como o volume e a natureza dos dados, a disponibilidade de recursos computacionais, a necessidade de precisão e a granularidade da análise desejada. Para o contexto das avaliações de disciplinas em português, o uso de modelos Transformer pré-treinados em português, como o BERTimbau ou RoBERTa com fine-tuning para o domínio específico, pode oferecer os melhores resultados em termos de precisão e compreensão contextual.

2.1.5 Trabalhos Relacionados

A análise de sentimentos em avaliações de disciplinas no contexto educacional tem se mostrado uma ferramenta valiosa para compreender a percepção dos estudantes e subsidiar a gestão acadêmica. Alguns estudos recentes exploram essa aplicação, utilizando diferentes técnicas e abordagens para extrair informações de dados textuais.

Um estudo recente de ??) propõe uma arquitetura para mineração de sentimentos a partir de avaliações online de cursos. Para isso, utilizou-se uma abordagem baseada em aprendizado de máquina e modelos como o BERT e RoBERTa, destacando a importância da análise de sentimentos para melhorar a qualidade do ensino e a experiência do aluno. A pesquisa mostra como a identificação de padrões de sentimentos pode fornecer *feedback* construtivo para educadores e administradores de cursos, auxiliando na tomada de decisões estratégicas para uma melhoria contínua.

Na mesma direção, ??) investigaram a aplicação de técnicas de análise de sentimentos para avaliar o *feedback* de estudantes. O trabalho ressalta a capacidade da análise de sentimentos na identificação de pontos fortes e fracos dos programas, permitindo uma resposta mais ágil e direcionada às necessidades dos estudantes.

Já no estudo de ??), explorou-se o uso de *big data* e análise de sentimentos para entender a percepção dos alunos sobre o ambiente de aprendizado em instituições de ensino, utilizando informações de um *website* com mais de 8000 avaliações. Embora o foco seja mais amplo, o trabalho aborda a relevância da análise de sentimentos para aprimorar a experiência educacional, fornecendo informações sobre o engajamento e a satisfação dos estudantes.

Esses trabalhos demonstram a relevância e o potencial da análise de sentimentos para aprimorar a gestão educacional, oferecendo uma visão agregada e estratégica a partir de grandes volumes de avaliações, o que corrobora com o objetivo proposto para este trabalho.

3 DESENVOLVIMENTO

Este capítulo detalha a metodologia de pesquisa empregada, abrangendo a descrição da base de dados utilizada, o processo de pré-processamento, a rotulação dos dados, o *fine-tuning* dos Modelos de Linguagem de Grande Escala (LLMs) e, por fim, as métricas de avaliação de desempenho dos modelos classificadores de sentimento desenvolvidos.

3.1 Descrição e Tratamento da Base de Dados

A base de dados utilizada neste trabalho é composta por cerca de 16.500 registros de avaliações anônimas de estudantes, coletadas no período de 2017 a 2023. Cada registro corresponde a uma avaliação individual, contendo informações referentes ao curso, disciplina, turma, data e hora da resposta, bem como as notas atribuídas e os comentários textuais dos alunos.

3.1.1 Estrutura dos Dados

O *dataset* apresenta a seguinte estrutura de colunas:

- **Identificadores e Contexto:** ID (identificador único), Curso, Disciplina, Turma e Data/Hora (momento do preenchimento).
- **Notas Quantitativas (C1 a C14):** 14 colunas contendo notas inteiras de 1 a 5, distribuídas em três categorias de avaliação.
- **Comentários Qualitativos (C15, C16, C17):** 3 colunas de texto livre, que são o foco da análise de sentimentos.

As três categorias de avaliação são apresentadas na Tabela ??.

Tabela 1 – Categorias de avaliação e seus respectivos critérios

Categoria	Critérios de Notas	Critério de Comentário	Contexto
I	C1, C2, C3	C15	Características e condições da oferta da disciplina
II	C4 a C9	C16	Práticas e atividades do docente na disciplina
III	C10 a C14	C17	Autoavaliação na disciplina

As colunas C15, C16 e C17 são o foco principal deste estudo, pois contêm os textos utilizados na análise de sentimentos. As demais colunas são utilizadas como atributos de apoio, podendo contribuir para a contextualização dos sentimentos expressos pelos estudantes.

3.1.2 Tratamento dos Dados

O processo de tratamento dos dados foi conduzido com o objetivo de garantir a qualidade e a consistência das informações textuais antes da aplicação das técnicas de Processamento de Linguagem Natural (PLN). As etapas de tratamento seguiram os seguintes passos:

- **Verificação de dados ausentes:** realizou-se uma inspeção para identificar e tratar valores nulos (NaN) ou vazios, especialmente nas colunas de texto (C15, C16 e C17). Caso os três comentários fossem ausentes, o registro era descartado;
- **Uniformização de tipos de dados:** garantiu-se que as colunas de datas (Data Hora) estivessem no formato de data/hora adequado e que as notas (C1 a C14) fossem tratadas como variáveis numéricas (inteiros);
- **Limpeza de texto:** embora o pré-processamento mais detalhado ocorra na Seção ??, uma limpeza inicial no texto livre incluiu a remoção de caracteres especiais não informativos ou pontuações excessivas (ex.: “!!!!”), conversão para letras minúsculas e exclusão de emoticons ou emojis, que não foram observados na base.

Esses procedimentos visaram reduzir a dimensionalidade do texto e eliminar ruídos que poderiam comprometer o desempenho dos modelos de aprendizado de máquina.

3.1.3 Separação de Dados para Rotulação Manual

Para o treinamento dos modelos de classificação, é imprescindível um conjunto de dados com sentimento pré-rotulado. Uma amostra de aproximadamente 500 registros foi extraída da base de dados principal, buscando representar a diversidade temporal (2017–2023), de cursos e disciplinas, a fim de evitar viés em subconjuntos específicos.

Essa amostra foi exportada para um novo arquivo .csv, contendo as colunas de texto (C15, C16 e C17). Este arquivo serviu como base para o pré-processamento da Seção ??, onde foram adicionadas as colunas de sentimento (`Sentimento_C15`, `Sentimento_C16` e `Sentimento_C17`) com os valores *negativo*, *neutro* e *positivo*.

3.2 Pré-processamento e Rotulação dos Dados

Esta seção detalha as etapas de pré-processamento e a estratégia de rotulação empregada para a criação do *dataset* de treinamento.

3.2.1 Pré-processamento de Texto

O pré-processamento do texto livre é crucial para otimizar o desempenho dos modelos de *Machine Learning* e LLMs. Os seguintes passos foram aplicados às colunas C15, C16 e C17:

- **Remoção de *stop words*:** eliminação de palavras comuns da língua portuguesa que não agregam valor ao sentimento (ex.: de, a, o, um, uma);
- **Tokenização:** divisão do texto em unidades menores (palavras ou subpalavras) que os modelos conseguem processar;
- **Lematização/Stemming:** redução das palavras às suas raízes (lematização) ou radicais (stemming) para tratar variações morfológicas (ex.: “estudando”, “estudou”, “estuda” → “estudar”);
- **Tratamento de negações:** manutenção da informação de negação, fundamental para a análise de sentimento (ex.: transformar “não gostei” em “não_gostei” ou preservar “não” como token relevante).

3.2.2 Rotulação Auxiliada por LLM

A rotulação manual de 500 registros é um processo custoso em tempo. Para otimizar e agilizar o processo, utilizou-se uma estratégia de pré-classificação com LLM, seguida por validação humana.

Essa pré-classificação foi realizada com o auxílio do modelo Gemini, que analisou os comentários das colunas C15, C16 e C17 e atribuiu rótulos de sentimento (*negativo*, *neutro* ou *positivo*). Isso gerou três novas colunas: *Sentimento_C15*, *Sentimento_C16* e *Sentimento_C17*.

A validação humana foi então conduzida sobre os 500 registros, ajustando classificações ambíguas ou incorretas e garantindo que os rótulos refletissem fielmente o contexto acadêmico e a intenção do aluno.

Ao final desta etapa, obteve-se um *dataset* rotulado, pronto para ser utilizado no treinamento e *fine-tuning* dos modelos.

3.2.3 Preparação para o Treinamento do Modelo

Com os dados rotulados, a base foi dividida em dois subconjuntos: 80% para treinamento e 20% para validação. Essa divisão visa garantir um balanceamento adequado entre a capacidade de aprendizado e a generalização dos modelos.

3.2.4 Modelagem e Fine-Tuning dos Modelos de Linguagem

Após o pré-processamento e rotulação, aplicou-se a técnica de *Fine-Tuning* (ajuste fino) para adaptar modelos pré-treinados de arquitetura Transformer ao domínio específico dos comentários acadêmicos em português. Foram empregados dois modelos de referência, ambos pré-treinados em grandes corpora de texto em língua portuguesa: o BERTimbau e o RoBERTa (variante em português).

O objetivo do *fine-tuning* foi gerar dois modelos classificadores otimizados, capazes de identificar sentimentos (*negativo*, *neutro*, *positivo*) nos comentários das avaliações realizadas pelos alunos.

3.3 Avaliação dos Modelos Classificadores

A performance dos modelos (BERTimbau e RoBERTa, após *fine-tuning*) foi avaliada utilizando métricas padrão de classificação, calculadas a partir da Matriz de Confusão.

3.3.1 Matriz de Confusão e Métricas de Desempenho

A Matriz de Confusão é uma tabela que permite visualizar o desempenho de um algoritmo de classificação, indicando o número de classificações corretas e incorretas por classe. Os termos-chave utilizados são:

- **Verdadeiros Positivos (VP):** instâncias positivas classificadas corretamente como positivas;
- **Verdadeiros Negativos (VN):** instâncias negativas classificadas corretamente como negativas;
- **Falsos Positivos (FP):** instâncias negativas classificadas incorretamente como positivas (Erro Tipo I);
- **Falsos Negativos (FN):** instâncias positivas classificadas incorretamente como negativas (Erro Tipo II).

Com base na Matriz de Confusão, as seguintes métricas foram utilizadas para comparar a eficácia dos classificadores:

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN} \quad (3.1)$$

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (3.2)$$

$$\text{Revocação (Recall)} = \frac{VP}{VP + FN} \quad (3.3)$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Precisão} \cdot \text{Revocação}}{\text{Precisão} + \text{Revocação}} \quad (3.4)$$

Essas métricas permitem avaliar a capacidade dos modelos em classificar corretamente os sentimentos, considerando o equilíbrio entre falsos positivos e falsos negativos.

3.4 Conclusão

Este capítulo apresentou a metodologia adotada para o desenvolvimento dos modelos classificadores de sentimento, desde a descrição e tratamento da base de dados, passando pelo pré-processamento e rotulação, até o *fine-tuning* dos modelos e a avaliação de seu desempenho. As etapas descritas garantem a robustez do processo e a confiabilidade dos resultados obtidos, que serão discutidos no próximo capítulo.

4 CONCLUSÃO

REFERÊNCIAS

- BóBó, M. *et al.* Análise de sentimento na educação: Um mapeamento sistemático da literatura. In: **Anais do XXX Simpósio Brasileiro de Informática na Educação (SBIE 2019)**. [S.l.: s.n.]: Brazilian Computer Society (Sociedade Brasileira de Computação - SBC), 2019. (SBIE 2019), p. 249.
- DEVLIN, J. *et al.* **BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding**. 2019. Disponível em: <https://arxiv.org/abs/1810.04805>.
- GANESAN, K. **The Business Case for AI: A Leader's Guide to AI Strategies, Best Practices & Real-World Applications**. Opinosis Analytics Publishing, 2022. ISBN 9781544528717. Disponível em: <https://books.google.com.br/books?id=Vn34zgEACAAJ>.
- GRLJEVIĆ, O.; BOŠNJAK, Z.; KOVAČEVIĆ, A. Opinion mining in higher education: a corpus-based approach. **Enterprise Information Systems**, Taylor & Francis, v. 16, n. 5, p. 1773542, 2022. Disponível em: <https://doi.org/10.1080/17517575.2020.1773542>.
- HU, M.; LIU, B. Mining and summarizing customer reviews. In: **Proceedings of the Tenth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. New York, NY, USA: Association for Computing Machinery, 2004. (KDD '04), p. 168–177. ISBN 1581138881. Disponível em: <https://doi.org/10.1145/1014052.1014073>.
- ISLAM, N. S. M. M. Comparative study on machine learning algorithms for sentiment classification. **International Journal of Computer Applications**, Foundation of Computer Science (FCS), NY, USA, New York, USA, v. 182, n. 21, p. 1–7, Oct 2018. ISSN 0975-8887. Disponível em: <https://ijcaonline.org/archives/volume182/number21/30054-2018917961/>.
- KOUFAKOU, A. Deep learning for opinion mining and topic classification of course reviews. **Education and Information Technologies**, v. 29, n. 3, p. 2973–2997, 2024. ISSN 1573-7608. Disponível em: <https://doi.org/10.1007/s10639-023-11736-2>.
- LIU, B. **Sentiment Analysis and Opinion Mining**. [S.l.: s.n.]: Morgan & Claypool Publishers, 2012. ISBN 1608458849.
- LIU, B. Introduction. In: _____. **Sentiment Analysis: Mining Opinions, Sentiments, and Emotions**. [S.l.: s.n.]: Cambridge University Press, 2020. (Studies in Natural Language Processing), p. 1–17.
- MEDHAT, W.; HASSAN, A.; KORASHY, H. Sentiment analysis algorithms and applications: A survey. **Ain Shams Engineering Journal**, v. 5, n. 4, p. 1093–1113, 2014. ISSN 2090-4479. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2090447914000550>.
- PANG, B.; LEE, L. **A Sentimental Education: Sentiment Analysis Using Subjectivity Summarization Based on Minimum Cuts**. 2004. Disponível em: <https://arxiv.org/abs/cs/0409058>.

PATEL, S.; SACHIN, D. "a comparative study of supervised and unsupervised classification techniques for sentiment analysis in imdb". *In: . [S.l.: s.n.], 2024.*

ROMERO, C.; VENTURA, S. Educational data mining and learning analytics: An updated survey. **WIREs Data Mining and Knowledge Discovery**, Wiley, v. 10, n. 3, jan. 2020. ISSN 1942-4795. Disponível em: <http://dx.doi.org/10.1002/widm.1355>.

SALGADO, H. Análise de sentimentos de tweets em língua portuguesa. *In: . [S.l.: s.n.], 2024.*

SHAIK, T. *et al.* Sentiment analysis and opinion mining on educational data: A survey. **Natural Language Processing Journal**, Elsevier BV, v. 2, p. 100003, mar. 2023. ISSN 2949-7191. Disponível em: <http://dx.doi.org/10.1016/j.nlp.2022.100003>.

SHAUKAT, Z. *et al.* Sentiment analysis on imdb using lexicon and neural networks. **SN Applied Sciences**, 2020.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. Bertimbau: Pretrained bert models for brazilian portuguese. *In: Intelligent Systems: 9th Brazilian Conference, BRACIS 2020, Rio Grande, Brazil, October 20–23, 2020, Proceedings, Part I*. Berlin, Heidelberg: Springer-Verlag, 2020. p. 403–417. ISBN 978-3-030-61376-1. Disponível em: https://doi.org/10.1007/978-3-030-61377-8_28.